Análisis de Datos con MongoDB

Alejandro Mancilla
Sr. Solutions Architect, LATAM
alejandro@mongodb.com
@alxmancilla

Agenda

- ¿Por qué hacer análisis con MongoDB?
- Crear ambiente de MongoDB
- Ingestión de datos en MongoDB (`mongoimport` / `mongorestore`)
- Exploración de datos (MongoDB Compass)
- Análisis de datos con MongoDB (Aggregation Framework)
- Extendiendo análisis con Python (`pymongo`)
- Integración con herramientas de BI (BI Connector)
- Extendiendo análisis con Apache Spark

Repositorio de GitHub: https://github.com/alxmancilla/DataDayMX

Análisis de Datos como Arte

> La ciencia es conocimiento que entendemos tan bien que podemos enseñarlo a una computadora”.
>
> Donald Knuth

“Computer Programming as an art”, Turing Award Lecture 1974

¿Por qué hacer análisis con MongoDB?

Aplicaciones & Datos

Consultar & Análisis

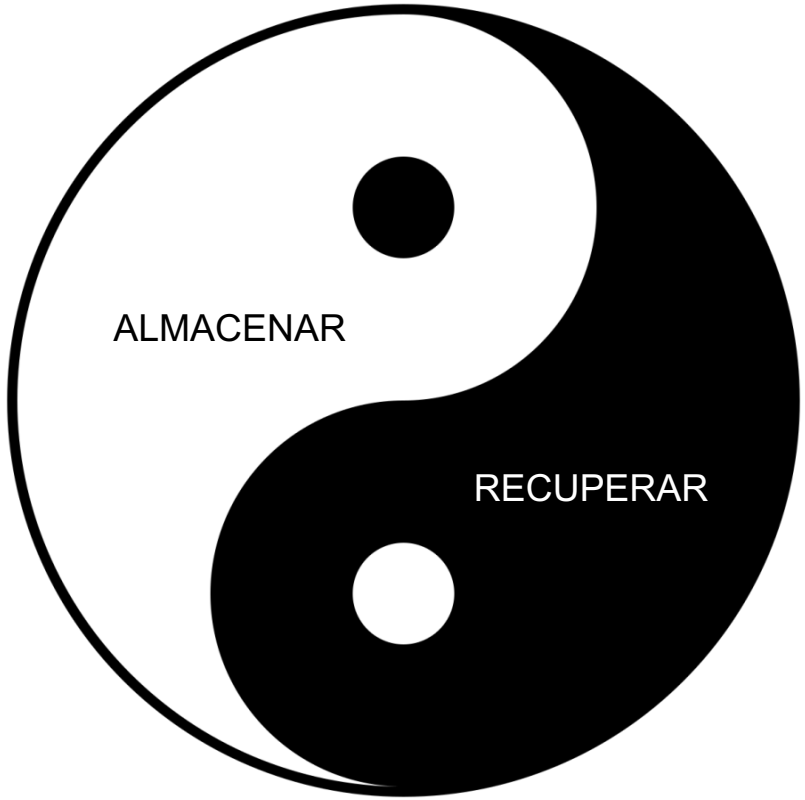

find() & aggregate()

Opciones para Analítica (1/2)

Pre-agregar

Agregar en otro lugar

Analizar en otro lugar

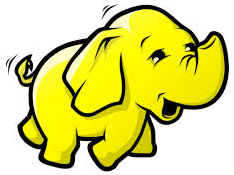

Spark

Escenario distribuido

Escenario distribuido

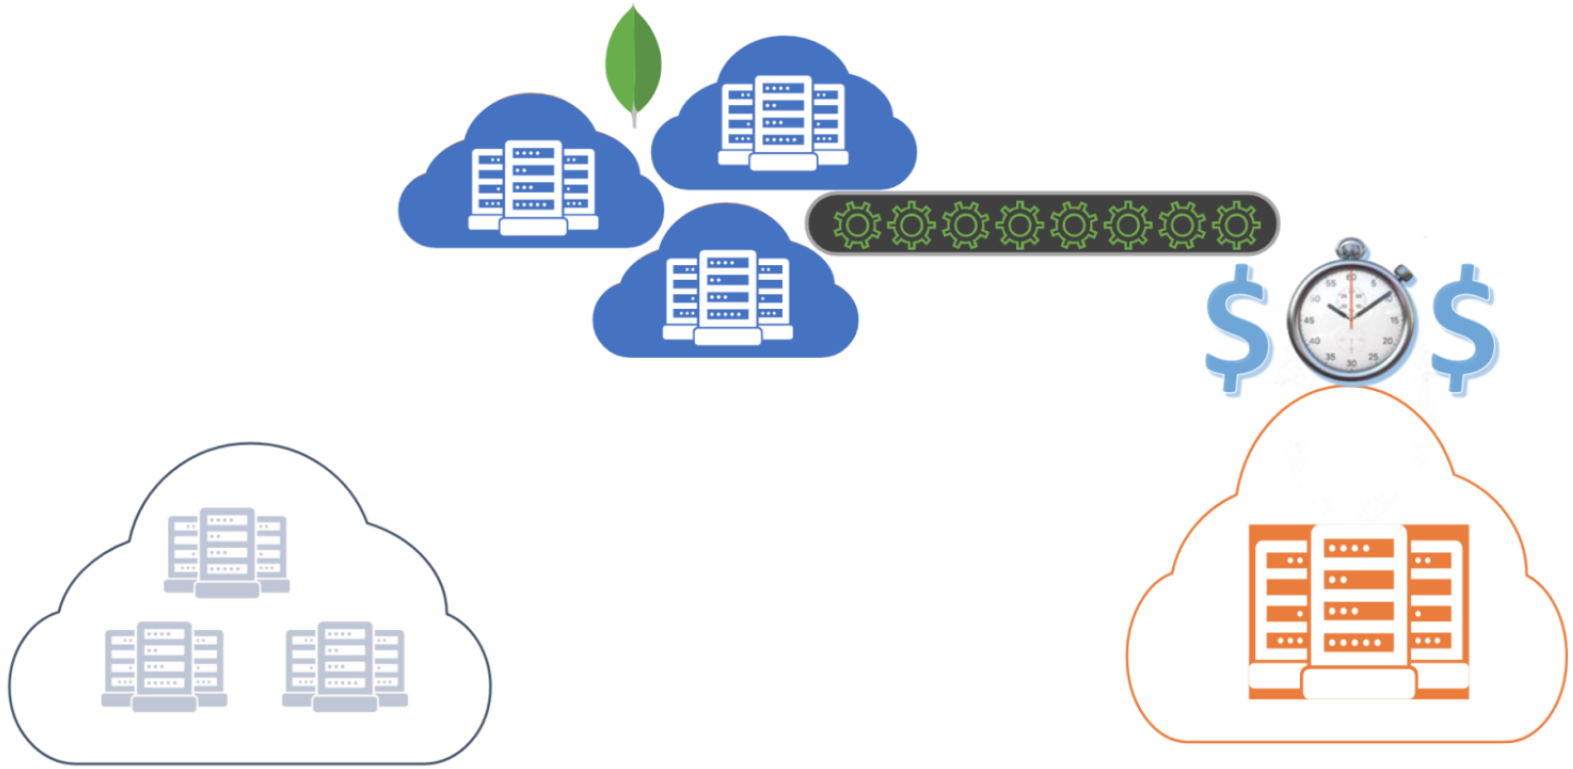

Opciones para Analítica (2/2)

Agregar en MongoDB

MongoDB La Base NoSQL Líder

Empresarial

Alto rendimiento

Escalable

```
{
  nombre: “Juan Perez”,
  pfxs: [“Dr.”,”Sr.”],
  direccion: “Reforma 321”,
  telefono: {
casa: 1234567890,
       movil: 5512345689
       }
}
```

Modelo de Datos
Documental

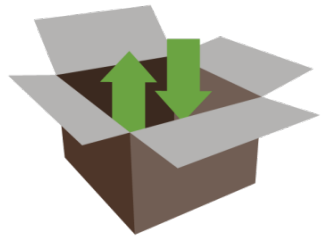

Open-Source

El Modelo de Datos de Documento

```
{
cliente_id : 12345,
nombre : 'Juan',
apellido : 'Pérez',
direccion : {
            calle : 'Av. Insurgentes Sur
321',
            colonia : 'Roma Norte',
            ciudad : 'Cuauhtémoc',
            estado : 'CDMX',
            cod_postal : '06700'
    }
polizas: [ {
        num_poliza : 132987,
        descripcion : 'short term',
        deducible : 500
},{
        num_poliza : 147001,
        descripcion : 'dental",
        visitas : 7
} ]
}
```

Coincide con los objetos de aplicación

- *Facilita el desarrollo*

Flexible

- *Evoluciona con la aplicación*

Alto rendimiento

- *Diseñado para el patrón de acceso*

Funcionalidad adicional

Consultas Expresivas	• Encuentra a alguien con el teléfono # "1-212 ..." • Compruebe si la persona con el número "555 ..." está en la lista de "no llamar"
Geo-espacial	• Encuentre la mejor oferta para el cliente en las coordenadas geográficas de Insurgentes y Reforma
Búsqueda Textual	• Encuentra todos los tweets que mencionan la empresa en los últimos 2 días
Agregación	• Contar y ordenar número de clientes por ciudad
Soporte nativo a JSON Binario (BSON)	• Agregue un número de teléfono adicional a Mario Robles sin volver a escribir el documento • Seleccione sólo el número de teléfono móvil en la lista • Ordenar por la fecha modificada
Left outer join ($lookup)	• Consulta todas las casas de CDMX, consulta sus transacciones y suma la cantidad por personar

MongoDB

```
{
    cliente_id : 1,
       nombre : "Mario",
       apellido : "Robles",
       ciudad : "CDMX",
       telefonos: [
       {    numero : “1-212-777-1212”,
              primario : true,
              tipo : “casa” },
     {
              numero : “1-212-777-
1213”,
              tipo : “cell”
       }
     ]
}
```

Te permite ubicar los datos donde los necesitas

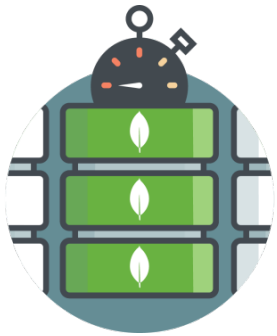

Disponibilidad

platforma resiliente con replicación y failover

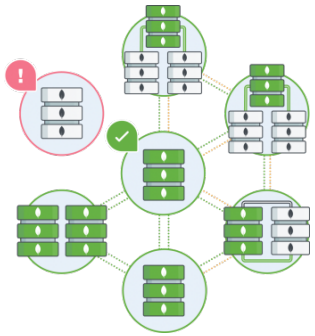

Escalabilidad

Crece horizontalmente con sharding nativo

Aislamiento de Carga de Trabajo

cargas operacionales y analiíticas en el mismo cluster

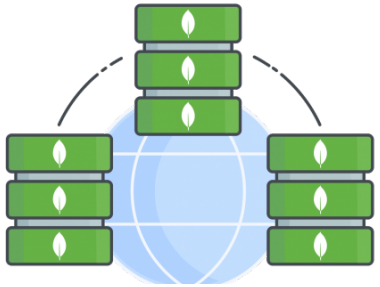

Localidad de datos

Gobierno, calidad de servicio, minimiza latencia

Corre igual en cualquier lugar (on-premises <-> cloud)

Servicio en la nube completamente administrado

Local

On-premises
Server & Mainframe

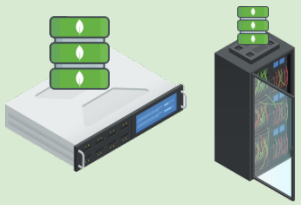

Nube privada

Nube híbrida

Nube pública

Crear ambiente de MongoDB

Clúster gratuito

Creación de perfil y cluster en MongoDB Atlas

https://cloud.mongodb.com/

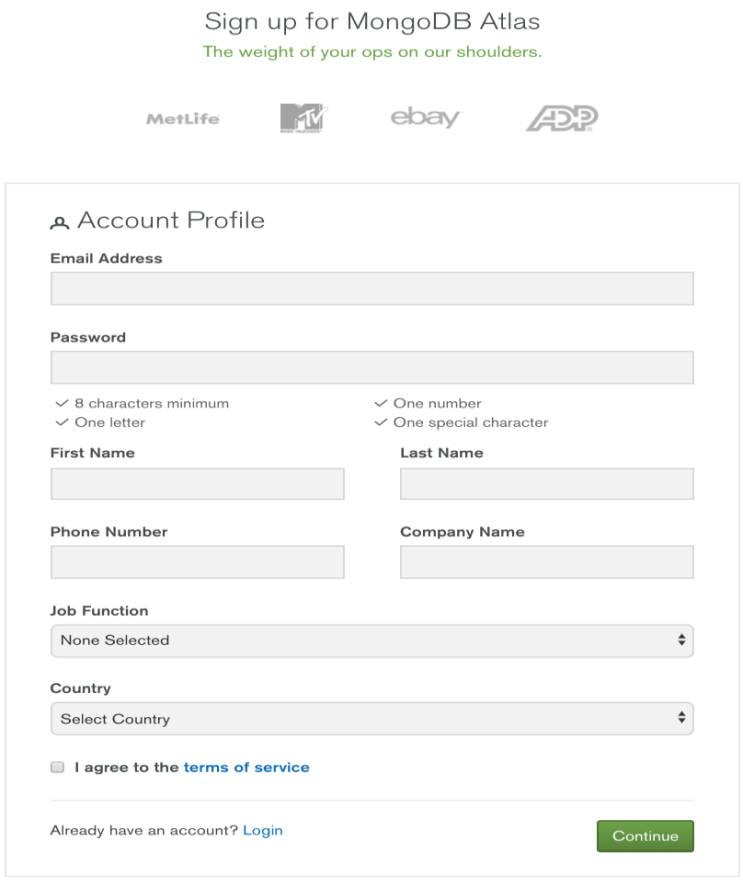

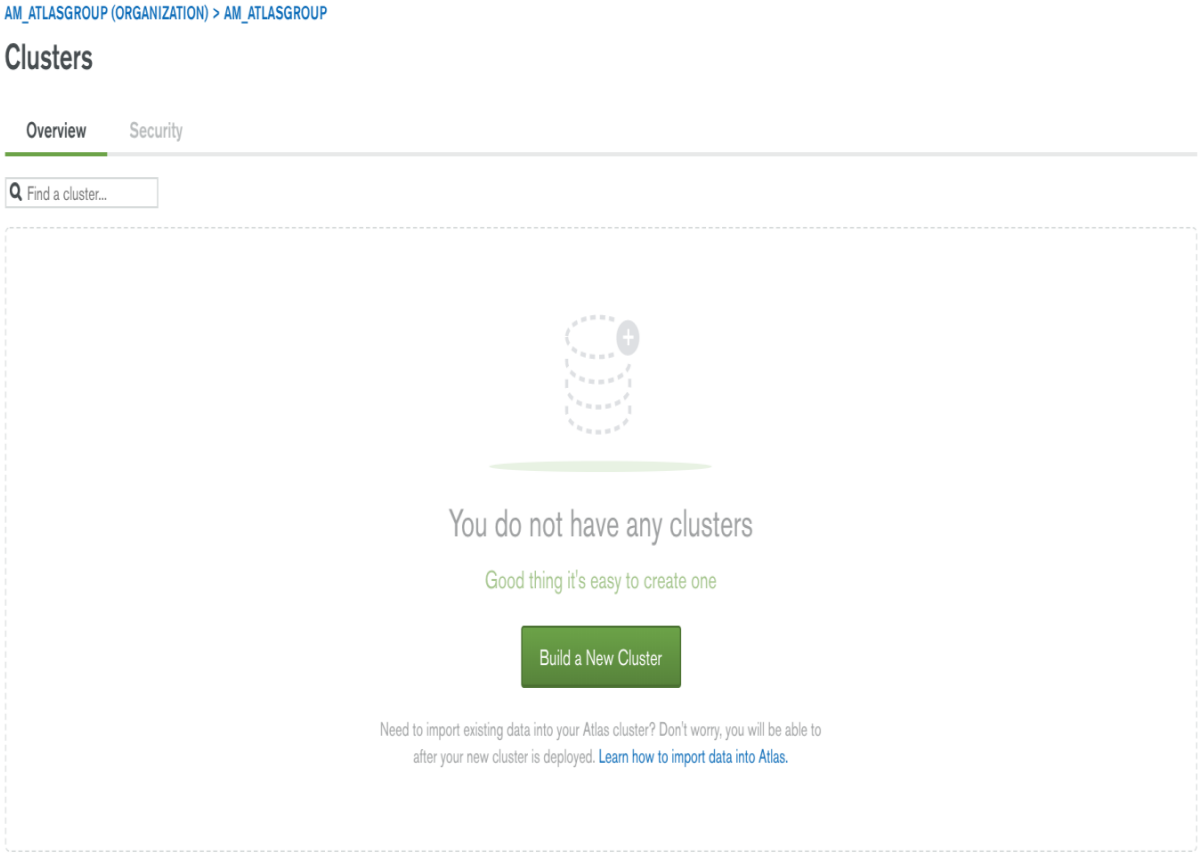

Descargar MongoDB

```
$ curl -O https://fastdl.mongodb.org/osx/mongodb-osx-ssl-x86_64-3.6.3.tgz
```

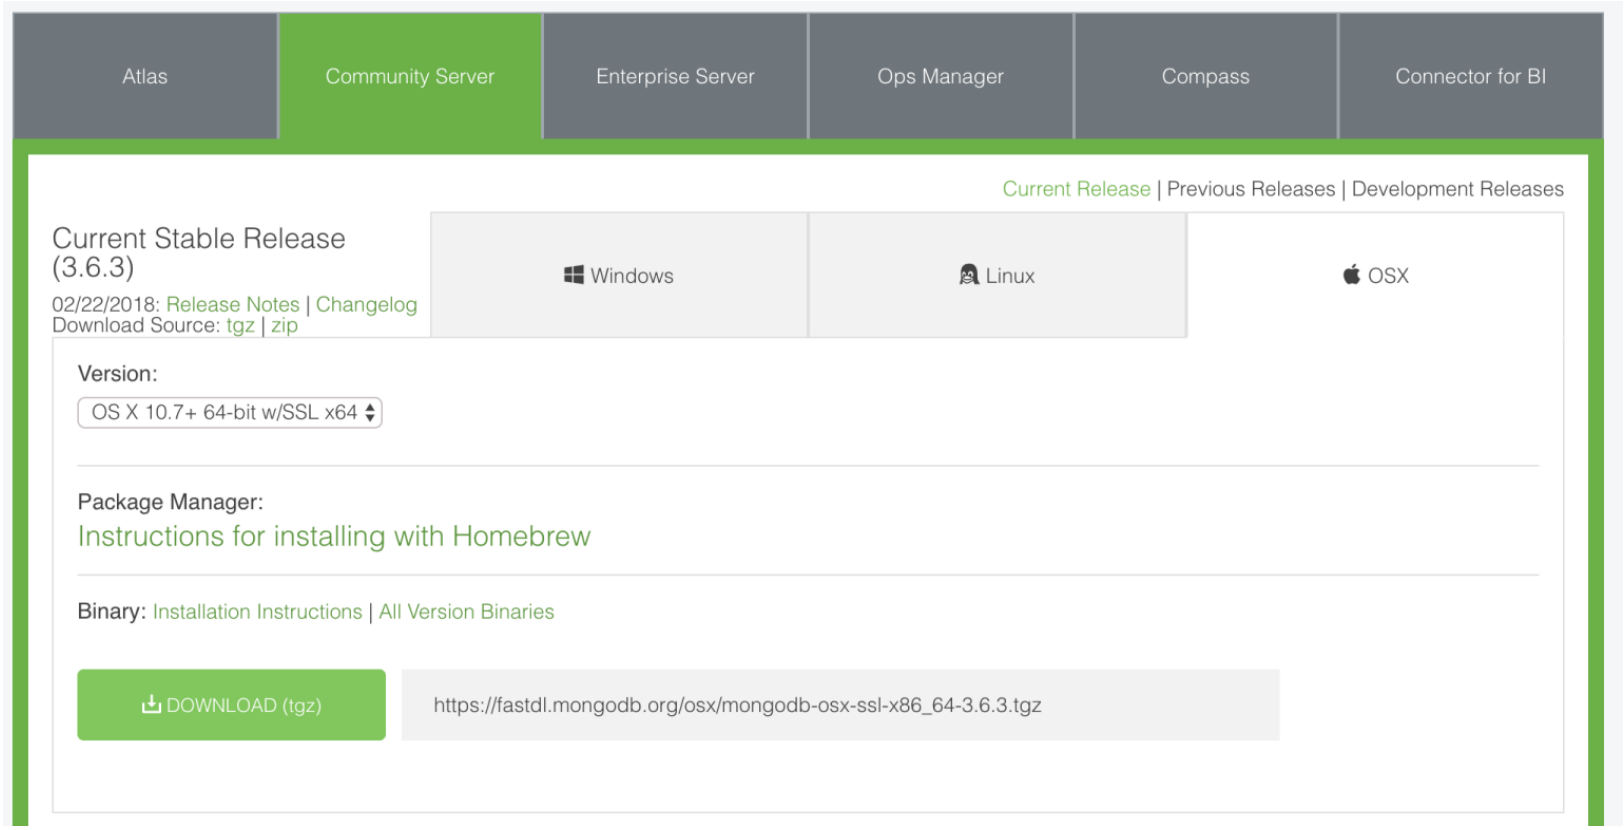

Descargar repositorio de GitHub

```
$ git clone https://github.com/alxmancilla/DataDayMX

Cloning into 'DataDayMX'...
remote: Counting objects: 112, done.
remote: Compressing objects: 100% (111/111), done.
remote: Total 112 (delta 56), reused 0 (delta 0), pack-reused 0
Receiving objects: 100% (112/112), 111.88 MiB | 857.00 KiB/s, done.
Resolving deltas: 100% (56/56), done.
```

Ejecutar un nodo stand alone (local)

```
# Crear un nodo stand alone

  $ mongod --dbpath rs_pss/m0 \
           --logpath rs_pss/m0/mongod.log \
           --port 27017 \
           --bind_ip 127.0.0.1 \
           --fork
```

Creación de un replica set (local)

```
# Crear un replica set
mongod --replSet rs_pss --dbpath rs_pss/m0 --port 27017 \
      --logpath rs_pss/m0/mongod.log --bind_ip 127.0.0.1 --fork
# Inicializar un replica set.
'rs.initiate({
     _id: "rs_pss",
     members: [
        { _id: 0, host: "127.0.0.1:27017" },
        { _id: 1, host: "127.0.0.1:27018" },
        { _id: 2, host: "127.0.0.1:27019" }]});' | mongo
```

Ingestión de datos a MongoDB

Herramientas `mongoimport` / `mongorestore`

Cargando datos usando `mongoimport` / `mongorestore`

```
# Se pueden cargar archivos .json/.csv y dumps de MongoDB.

$ mongoimport -d test -c restaurants --drop --file primer-dataset.json

$ mongoimport  -c books --drop --type csv --headerline --file ./dataset/books.csv

$ mongoimport  -c ratings --drop --type csv --headerline --file ./dataset/ratings.csv

$ mongorestore --dir=dump
```

Conexión al clúster desde el shell en tu laptop

```
# Acceder a localhost en puerto default 27017
$ mongo test
rs_pss:PRIMARY> show dbs
admin   0.000GB
config  0.000GB
local   0.094GB
test    0.220GB
rs_pss:PRIMARY> show collections
books
ratings
restaurants
zips
```

Consultar datos usando `findOne()` & `count()`

```
> db.books.findOne()
{
        "_id" : ObjectId("5aa890aa7fe2b08c22b6b246"),
        "book_id" : 2,
        "goodreads_book_id" : 3,
        "work_id" : 4640799,
        "books_count" : 491,
        "isbn" : 439554934,
        "authors" : "J.K. Rowling, Mary GrandPr¸",
        "original_publication_year" : 1997,
        "original_title" : "Harry Potter and the
Philosopher's Stone",
        "title" : "Harry Potter and the Sorcerer's Stone
(Harry Potter, #1)",
        "language_code" : "eng",
        "image_url" : "https://images.gr-
assets.com/books/1474154022m/3.jpg",
        "small_image_url" : "https://images.gr-
assets.com/books/1474154022s/3.jpg"
}
```

```
> db.ratings.findOne()
{
        "_id" :
ObjectId("5aa889807fe2b08c225974e8"),
        "user_id" : 2,
        "book_id" : 260,
        "rating" : 5
}
```

```
> db.books.count()
10000
```

```
> db.ratings.count()
5976479
```

Consultar datos usando `find()`

```
# Filtrar ratings del book_id igual a 1

> db.ratings.find({"book_id": 1})
{ "_id" : ObjectId("5aa889917fe2b08c225cd3eb"),
"user_id" : 2886, "book_id" : 1, "rating" : 5 }
{ "_id" : ObjectId("5aa889977fe2b08c225dfbdc"),
"user_id" : 6158, "book_id" : 1, "rating" : 5 }
...
```

Exploración de datos en MongoDB

Usando MongoDB Compass

MongoDB Compass

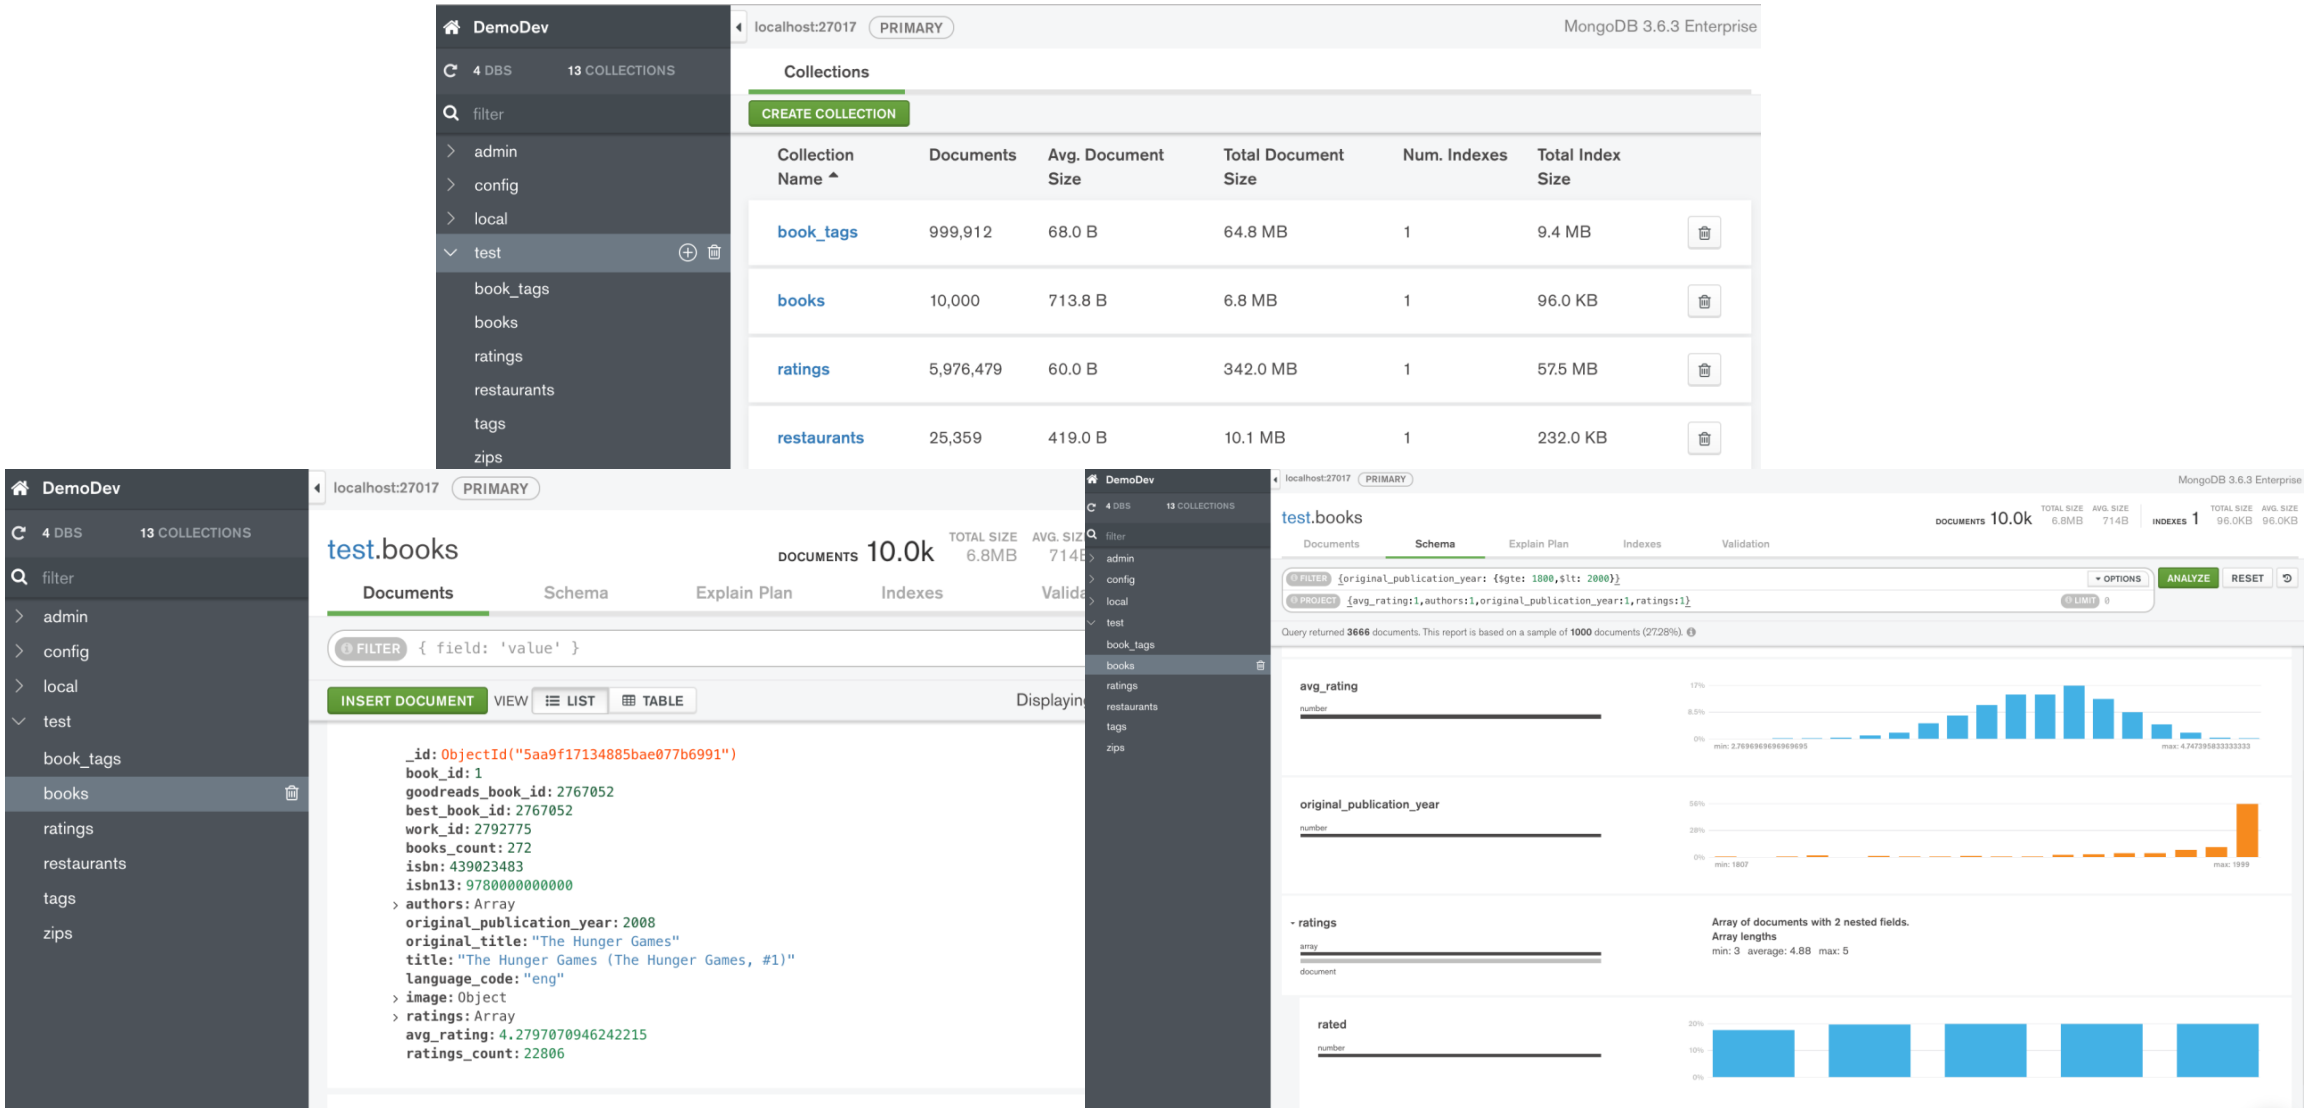

Análisis de datos con MongoDB

Usando `db.collection.aggregate()`

Sitio de recomendación de libros

Modelo del Framework de Agregación

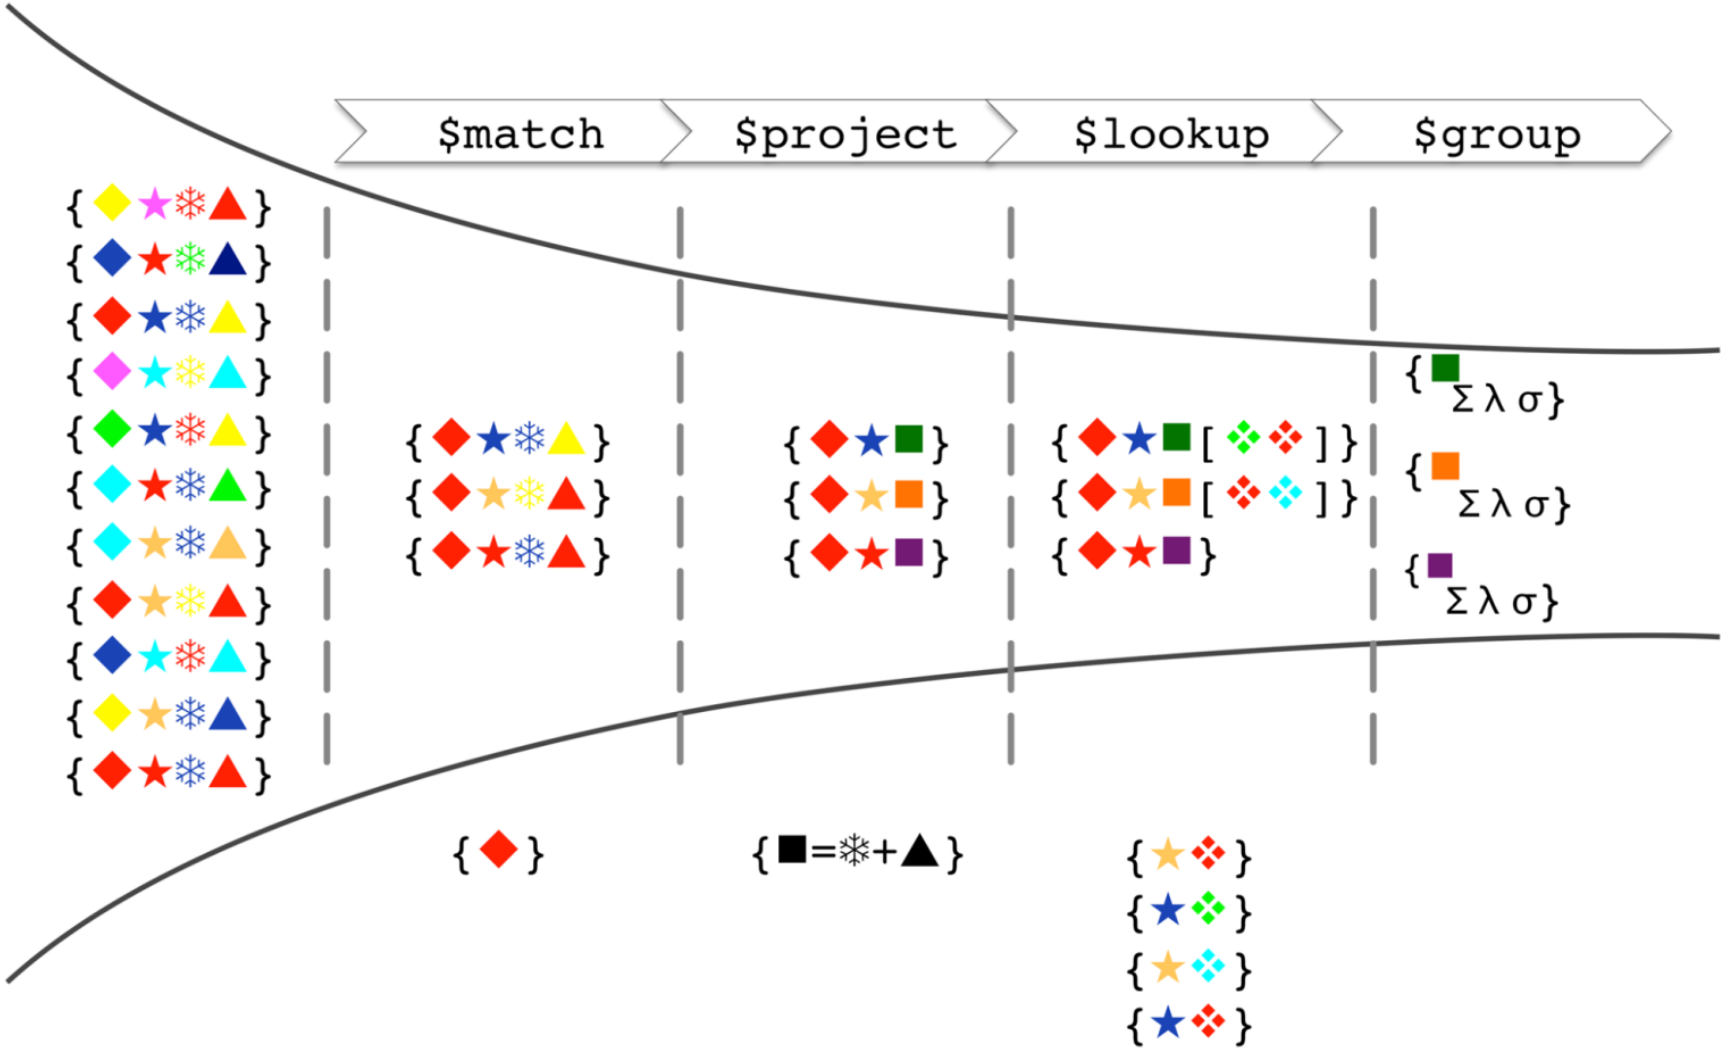

Aggregation Framework - $match & $group

```
# Filtrar ratings del book_id igual a 1
> db.ratings.aggregate([{$match: {"book_id": 1}}])
{ "_id" : ObjectId("5aa889917fe2b08c225cd3eb"), "user_id" : 2886, "book_id"
: 1, "rating" : 5 }
{ "_id" : ObjectId("5aa889977fe2b08c225dfbdc"), "user_id" : 6158, "book_id"
: 1, "rating" : 5 }
...
# Filtrar y después agrupar por rating y contar total por nivel de rating
> db.ratings.aggregate([{$match: {"book_id": 1}},
                        {$group: {_id: "$rating", total: {$sum:1}}}])
{ "_id" : 1, "total" : 231 }
{ "_id" : 3, "total" : 3013 }
...
```

Aggregation Framework - $sum , $avg & $sort

```
# Ratings por libro y su evaluación promedio, ordenados por book_id

> db.ratings.aggregate([{$group: {_id: "$book_id",
                           total: { $sum: 1},
                           promedio: {$avg: "$rating"}}},
                          {$sort: {"_id": 1}} ])
{ "_id" : 1, "total" : 22806, "promedio" : 4.2797070946242215 }
{ "_id" : 2, "total" : 21850, "promedio" : 4.351350114416476 }
{ "_id" : 3, "total" : 16931, "promedio" : 3.214340558738409 }
...
```

Aggregation Framework - $sum , $avg & $sort

```
# Histograma de libros ( mean, std dev, min, max )

> db.ratings.aggregate([{$group: {_id: "$book_id",
                                  total: { $sum: 1}}},
                        {$group: {_id: null, total: {$sum: 1},
                                  promedio: {$avg: "$total"},
                                  des_est: {$stdDevPop: "$total" },
                                  min: {$min: "$total"},
                                  max: {$max: "$total"}} } ])

{ "_id" : null, "total" : 10000, "promedio" : 597.6479, "des_est" :
1267.226422122578, "min" : 8, "max" : 22806 }
```

Aggregation Framework - $sort & $limit

```
# Histograma de libros ( mean, std dev, min, max )

> db.ratings.aggregate([{$group: {_id: "$book_id",
                                  total: { $sum: 1}}},
                        {$group: {_id: null, total: {$sum: 1},
                                  promedio: {$avg: "$total"},
                                  des_est: {$stdDevPop: "$total" },
                                  min: {$min: "$total"},
                                  max: {$max: "$total"}} } ])

{ "_id" : null, "total" : 10000, "promedio" : 597.6479, "des_est" :
1267.226422122578, "min" : 8, "max" : 22806 }
```

Demo del Aggregation Framework

Extendiendo análisis con Python

Usando `pymongo`

Drivers & Frameworks






MEAN Stack

Morphia

Instalación de pymongo

```
# Instalar  pymongo con pip
$ python -m pip install pymongo

# Verificar instalación de pymongo
$ python -c "import pymongo; print(pymongo.version);"
3.6.1
```

Ejemplo en Python - Conexión a MongoDB (1/2)

```
import pymongo
# Connection to Mongo DB
try:
    conn=pymongo.MongoClient("mongodb://localhost:27017")
    print "Connected successfully!!!"
    collection = conn.DataDayMX.wkshops
    # dictionary to be added in the database
    record={
        "title": "MongoDB and Python",
        "description": 'MongoDB is no SQL database',
        "tags": ['mongodb', 'database', 'NoSQL'],
        "viewers": 104}
```

Ejemplo en Python - Conexión a MongoDB (2/2)

```
# inserting the data in the database
    rec = collection.insert(record)
    print "Inserted record successfully!!!"

    for i in collection.find({"title": "MongoDB and Python"}):
        print(i)
    print "Docs returned successfully!!!"

except pymongo.errors.ConnectionFailure, e:
    print "Could not connect to MongoDB: %s" % e
conn.close()
```

Demo de Integración de MongoDB con Python

Integración con Numpy

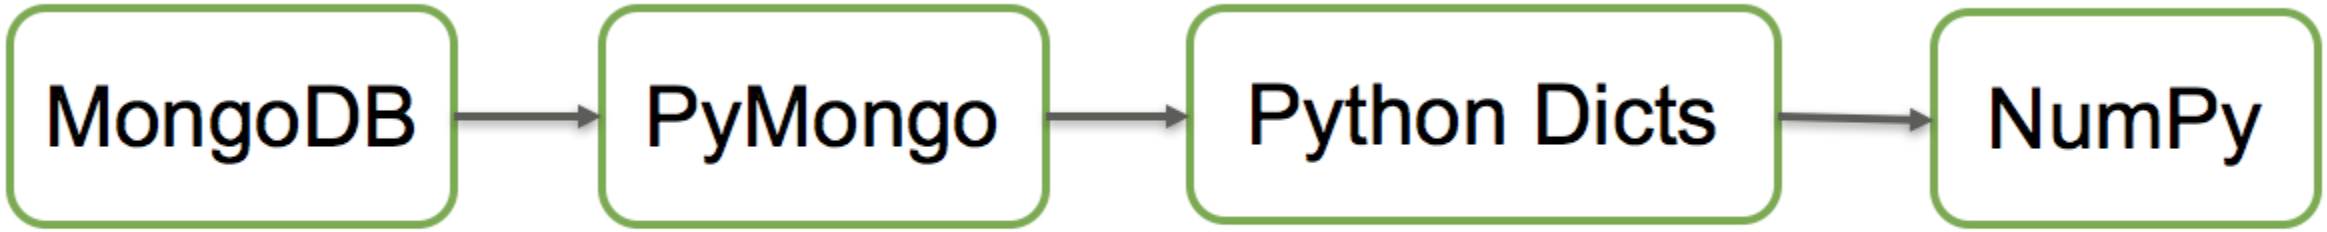


NumPy
Monary
Scikit - learn
mongoDB.
FOR GIANT IDEAS
Python
Cron
Airflow
Luigi
Pandas
Matlibplot
PyTables

Creación de Dashboards

Usando MongoDB BI Connector

MongoDB Conector para BI

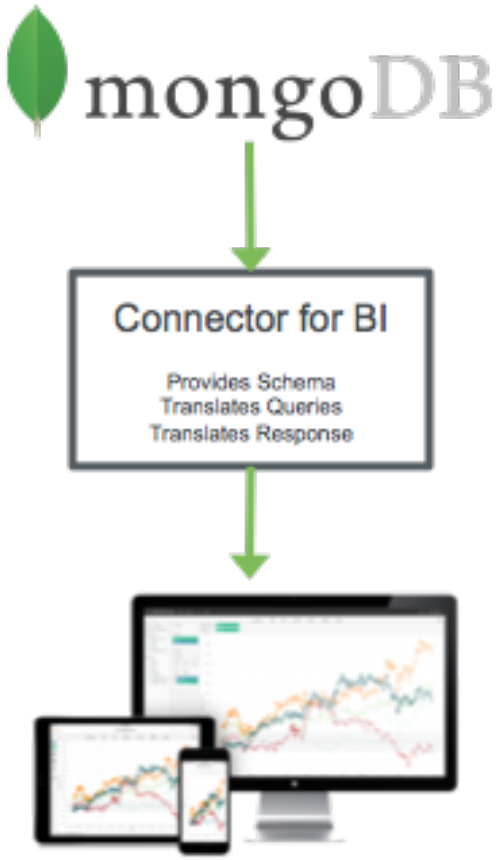

- Crea visualizaciones & analiítica desde herramientas de BI basadas en SQL
  - Muestreo automaático de esquemas
  - Elimina necesidad de ETL
- Rendimiento mejorado en la capa de re-escritura de SQL
  - Mayor procesamiento realizado en la base de datos
- Instalacioón y autenticación simplificada

Arquitectura del MongoDB Conector para BI

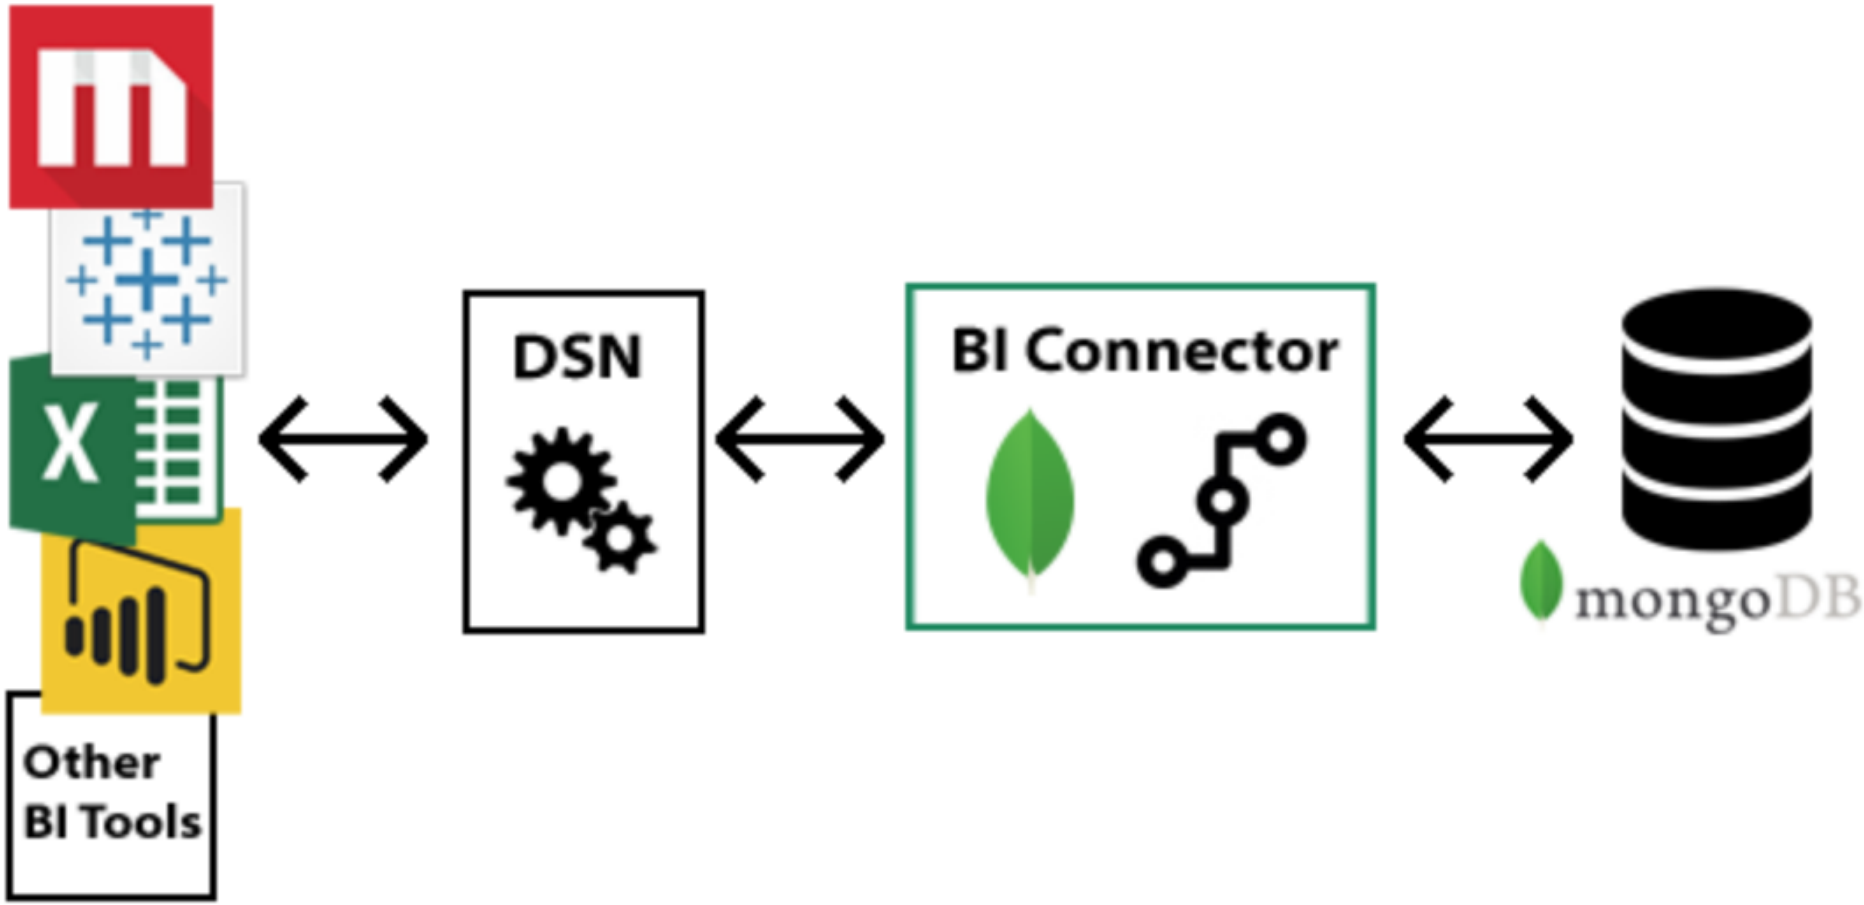

Analítica e Integración con BI

Demo del Conector para BI

Extendiendo análisis con Apache Spark

Usando MongoDB Connector

MongoDB Conector para Apache Spark

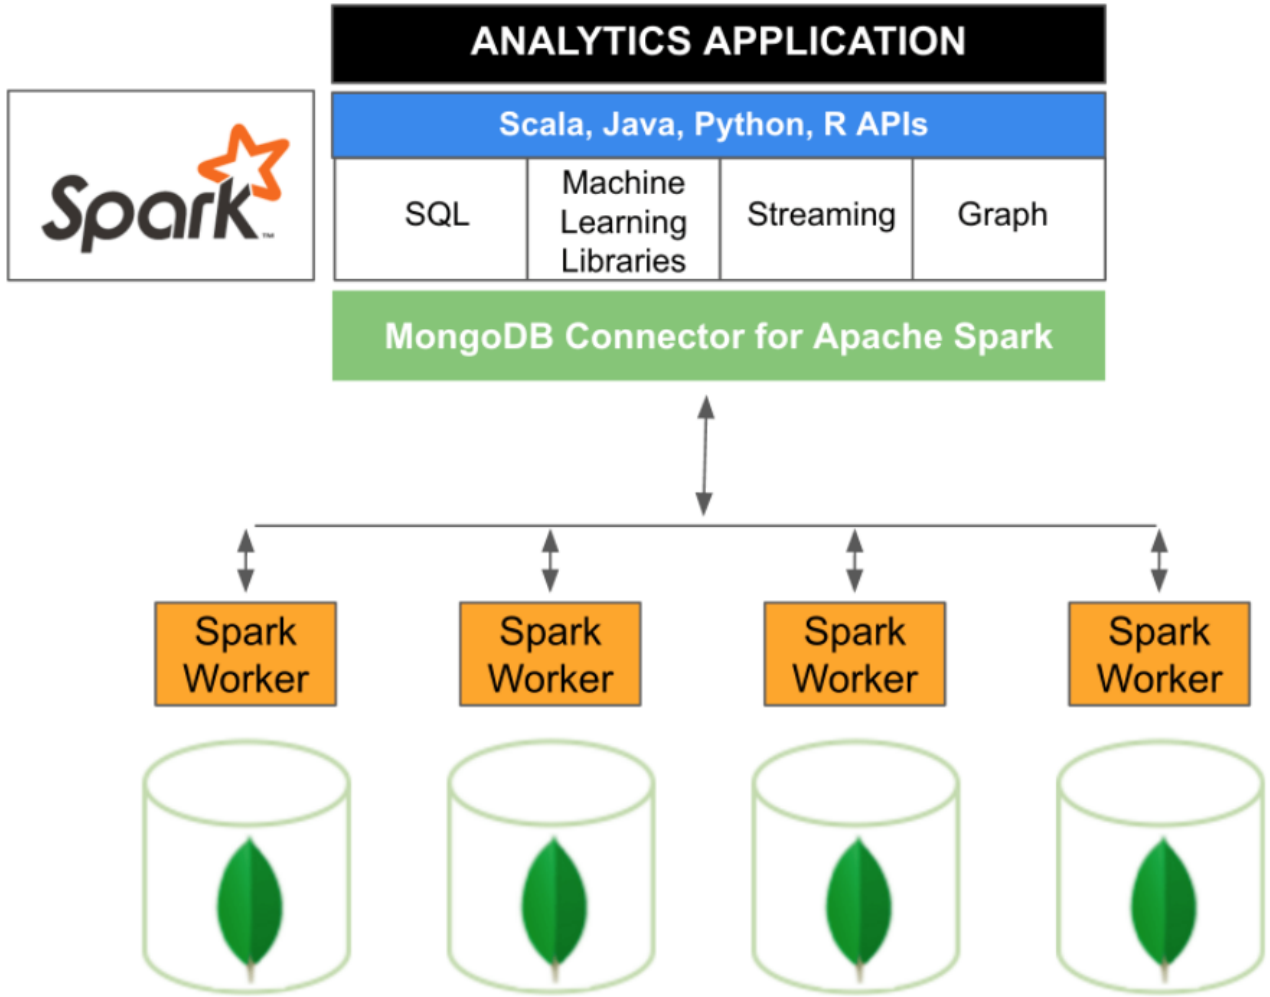

Data Lake Operacional

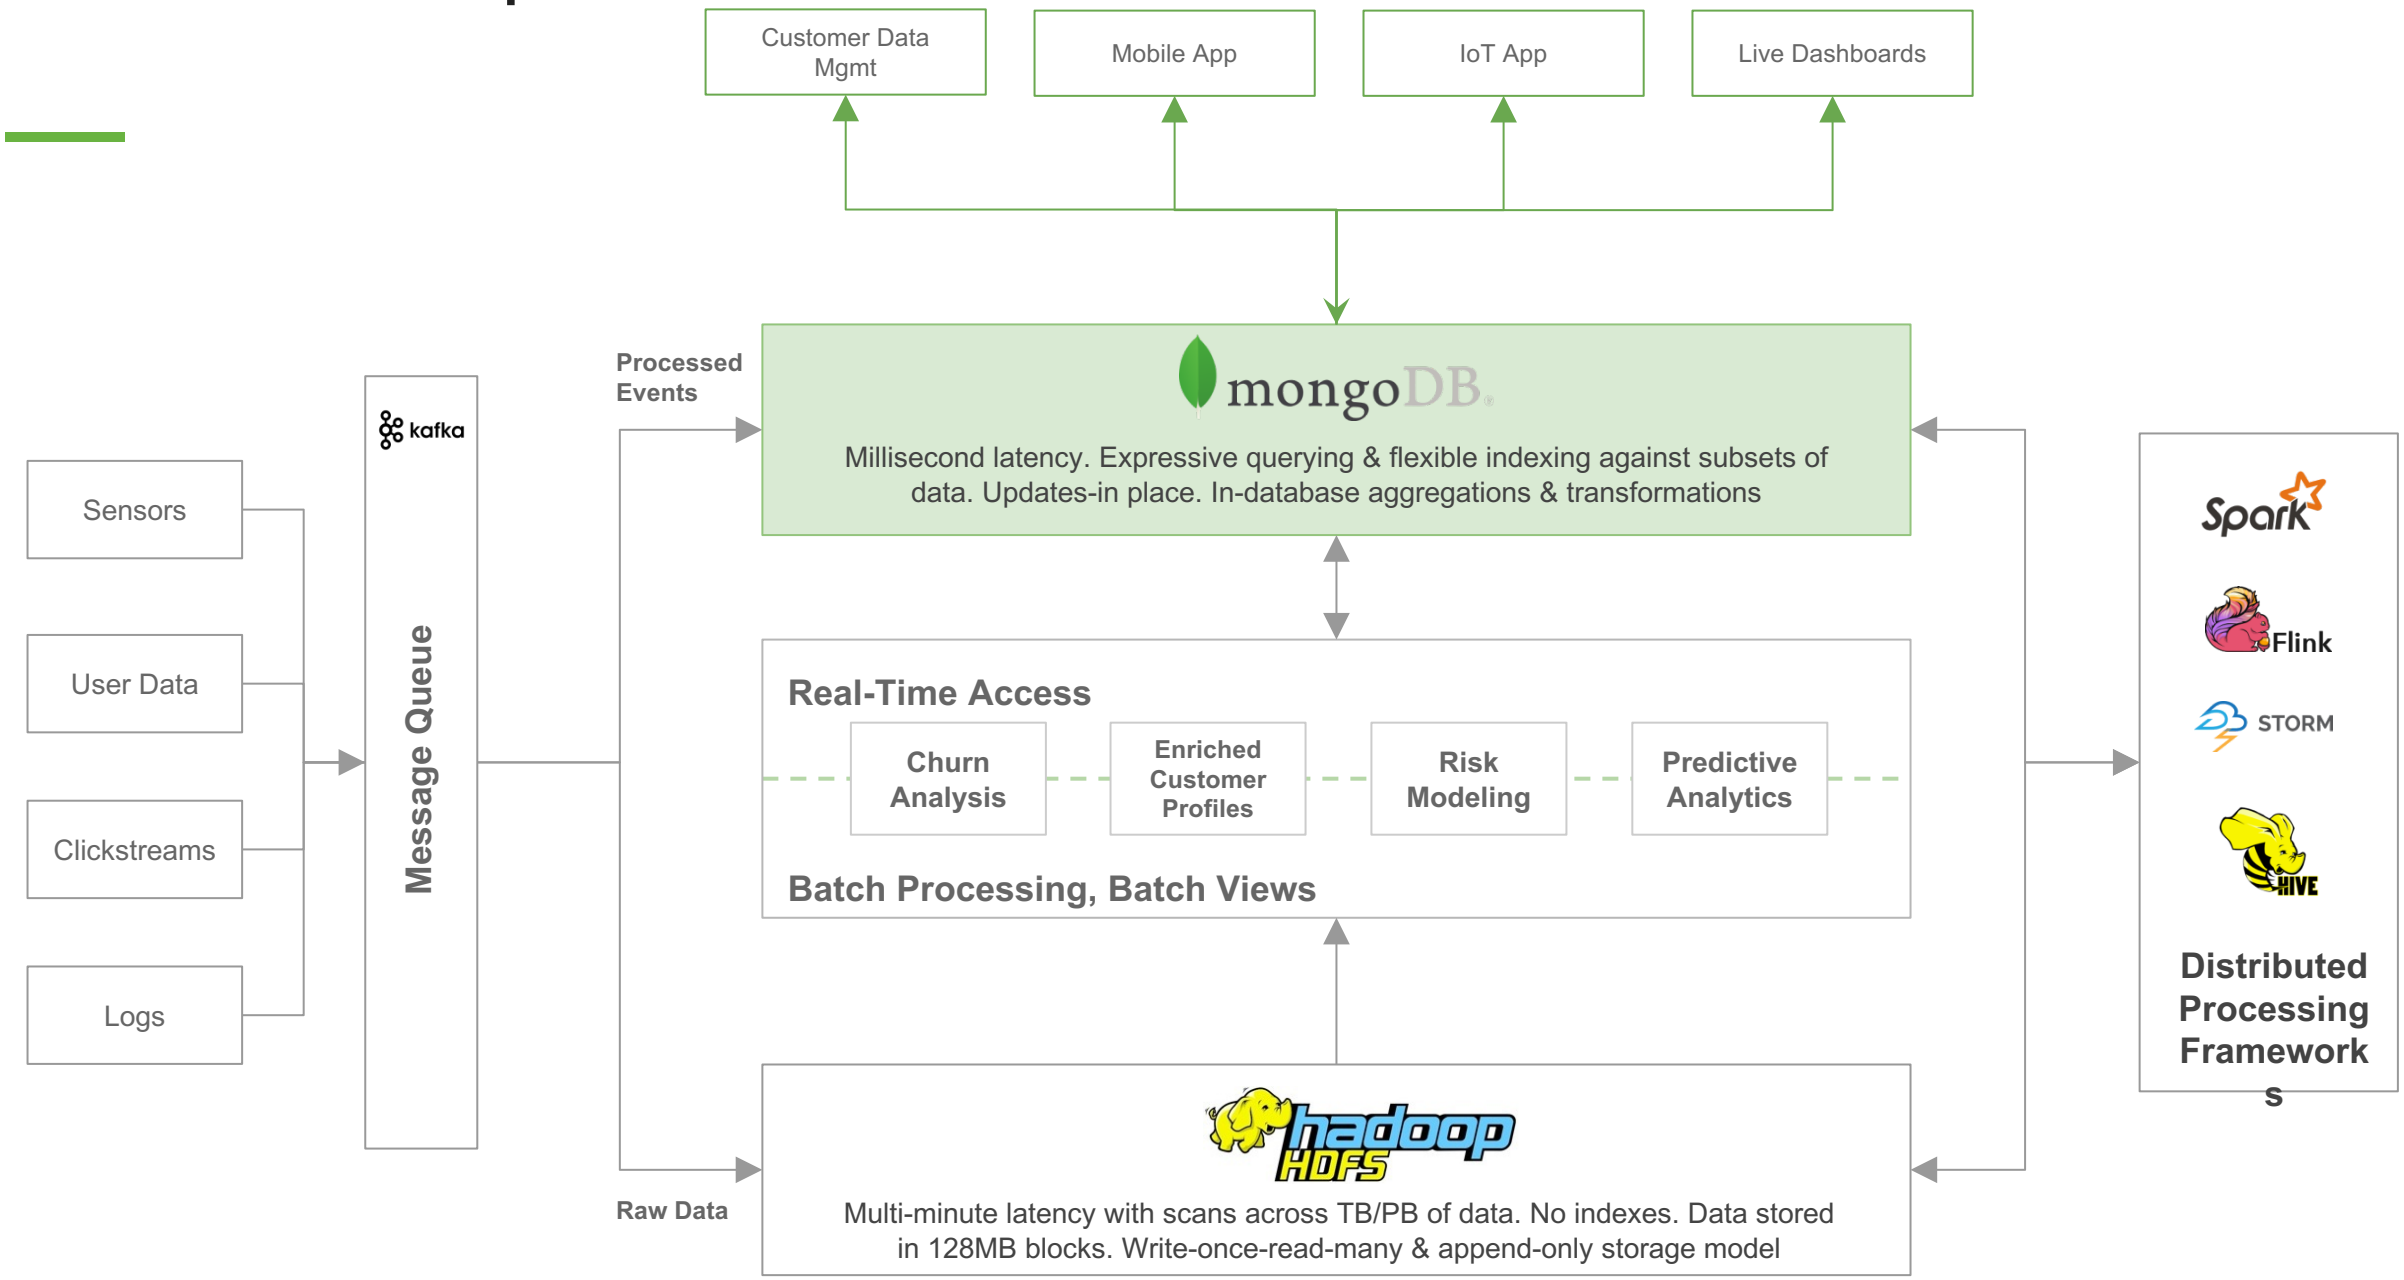

MongoDB University

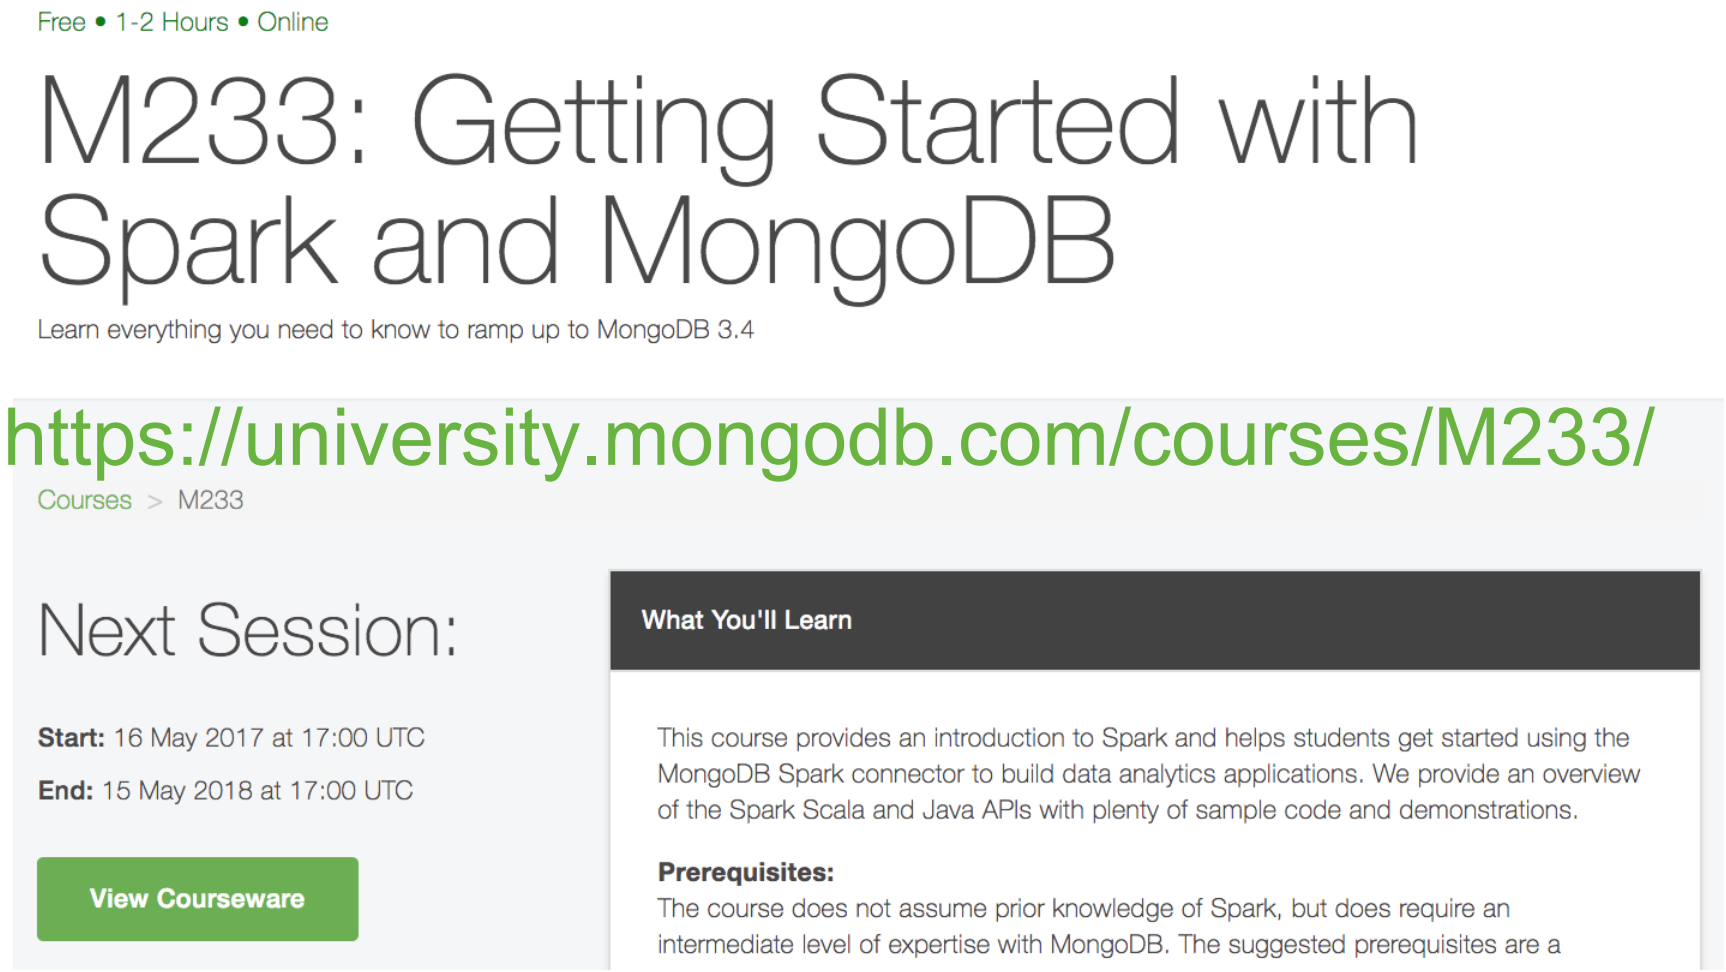

Q & A

Análisis de Datos con MongoDB

Alejandro Mancilla
Sr. Solutions Architect, LATAM
alejandro@mongodb.com
@alxmancilla